

Fine-tuning de CNN e RAG com LLM open-source

Um assistente multimodal para identificação de plantas medicinais

O que vamos construir hoje

0	Preparação	GPU T4, bibliotecas e configurações do projeto
1	Dataset	4.200 fotos reais de 14 plantas, baixadas do iNaturalist
2	Classificador de imagens	Fine-tuning da EfficientNet-B0 e avaliação no teste
3	RAG	Busca no guia com e5 + FAISS e resposta com o Qwen2.5
4	Chat multimodal	Foto e perguntas juntas, no mesmo chat

A IDEIA


Tire uma foto. Faça uma pergunta.

A IA reconhece a planta e responde com base num guia de fitoterápicos, citando a página de onde tirou a informação.

ARQUITETURA


Dois modelos, um pipeline

VISÃO



↓ o nome da planta entra junto com a pergunta

LINGUAGEM (RAG)



O PROBLEMA

14 plantas medicinais, 14 classes

Alecrim

Babosa

Boldo-brasileiro

Calêndula

Camomila

Capim-limão

Erva-cidreira-
brasileira (lípia)

Espinheira-santa

Gengibre

Hortelã

Manjeriçõ

Melissa

Tanchagem

Vinagreira (hibisco)

Cada planta é uma saída na última camada da CNN

Fotos reais, vindas do iNaturalist

14

espécies

300

fotos por espécie

4.200

fotos no total

Grau pesquisa primeiro: fotos com identificação confirmada pela comunidade

Créditos rastreáveis: autor, licença e link de cada foto em [creditos.csv](#)

Só licenças abertas: CC0, CC BY e CC BY-NC

Mundo real: vaso, quintal, mão, mercado, como uma foto de celular

Separar antes de treinar



■ **Treino · 70% · 2.940 fotos.** O modelo aprende aqui.

■ **Validação · 15% · 630.** Escolhe a melhor época.

■ **Teste · 15% · 630.** Nota final, nunca vista no treino.

A divisão é estratificada: cada conjunto mantém a mesma proporção de cada planta.

Data augmentation (só no treino)

- Recorte aleatório (50% a 100% da foto)
- Espelhamento horizontal
- Rotação de até 15°
- Brilho, contraste e saturação $\pm 25\%$

Cada época vê versões um pouco diferentes da mesma foto.

Como uma CNN enxerga uma folha



A **EfficientNet-B0** é uma CNN leve (cerca de 5 milhões de parâmetros), pré-treinada no ImageNet com 1.000 classes de objetos do dia a dia.

Transfer learning: três caminhos

Estratégia	O que é treinado	Quando faz sentido
Treinar do zero	A rede toda, pesos aleatórios	Milhões de imagens
Extração de features	Só a camada final	Poucos dados, pouco tempo
Fine-tuning completo	A rede toda, com lr baixo	O nosso caso

```
m = efficientnet_b0(weights=EfficientNet_B0_Weights.DEFAULT)
m.classifier[1] = nn.Linear(1280, 14) # nova cabeça: 14 plantas
AdamW(m.parameters(), lr=3e-4) # nenhuma camada congelada
```

A receita do treino

MODELO BASE

EfficientNet-B0

OTIMIZADOR

AdamW, lr 3e-4

AGENDADOR

Cosine annealing

PERDA

Cross-entropy + label
smoothing 0,1

PRECISÃO

Mista (AMP, FP16)

ÉPOCAS

10, batch de 32


TEMPO NA T4

~25 s por época

CHECKPOINT

Salva a melhor
validação

Acurácia de validação por época



93,65%

melhor validação, na época 7 (ponto em destaque)

83,97%

já na época 1: efeito do pré-treino

A nota final vem do conjunto de teste, na célula 7.

Quando o modelo deve dizer "não sei"

Limiar de confiança

1. O softmax dá uma probabilidade para cada planta
2. O chat mostra as 3 mais prováveis
3. Se a maior ficar abaixo de 50%, o sistema avisa que não tem certeza e pede outra foto

Erros esperados

Melissa × hortelã × manjeriço: folhas muito parecidas.
Uma foto mais perto das folhas ajuda.

Planta fora das 14: o limiar reduz o problema, mas uma CNN ainda pode dar confiança alta para algo que nunca viu.

Por que não perguntar direto ao LLM?

LLM sozinho

- Responde de memória
- Pode inventar uma dose
- Não diz de onde tirou
- Não se atualiza com o seu documento

LLM + RAG

- Busca os trechos certos no guia
- Responde só com esses trechos
- Cita a página
- Trocou o PDF, trocou o conhecimento

O RAG em seis passos

1 · Extrair

Texto do PDF página por página, com pypdf

2 · Dividir

Trechos de ~800 caracteres com 150 de sobreposição, sem cortar palavras

3 · Vetorizar

multilingual-e5-base, com os prefixos "passage:" e "query:"

4 · Indexar

FAISS IndexFlatIP com vetores normalizados, que equivale a similaridade de cosseno

5 · Buscar

Os 6 trechos mais parecidos; até 3 páginas inteiras vão para o modelo

6 · Gerar

Qwen2.5-3B-Instruct responde com base nessas páginas e cita a fonte

Regras para o modelo não inventar

No prompt de sistema

- Use somente os trechos fornecidos
- Não achou? "Não encontrei essa informação no documento."
- Não invente dados, doses ou indicações
- Em uso e dose, traga as contraindicações
- Cite a página: (pág. X)

Na geração

do_sample=False: a mesma pergunta gera a mesma resposta

Sem repetition_penalty: ela atrapalharia o modelo a copiar números e nomes do PDF

Streaming: o texto aparece enquanto é gerado

A foto vira contexto da pergunta

```
Você [Boldo-brasileiro]: qual a dose?
```

```
# o que vai para a busca e para o LLM:
```

```
"(Planta identificada na foto: Boldo-brasileiro) qual a dose?"
```

Comandos

foto · envia outra foto

limpar · esquece a planta

sair · encerra o chat

Perguntas para testar

Para que serve? · Como faço o chá? · Qual a dose? · Grávida pode usar? · Tem interação com remédios? · Com qual planta ela é confundida?

CUIDADOS

Limitações que precisam ficar claras



Projeto educativo. Não substitui médicos, farmacêuticos e outros profissionais de saúde.



A identificação pode errar. Nunca use uma planta só porque a IA disse o que ela é.



O RAG depende do documento. PDF escaneado não tem texto e precisaria de OCR.



Licenças. Parte das fotos é CC BY-NC: o dataset serve só para uso educativo e não comercial.

PRÓXIMOS PASSOS

- Mais fotos e mais épocas (células 2 a 7)
- Um reranker depois da busca
- Avaliar o RAG com perguntas e respostas de referência
- Interface web com Gradio
- Comparar com um modelo de visão e linguagem (VLM)

Obrigado! Perguntas?

Pedro Henrique Campos Moreira

linkedin.com/in/pedro-campos-5760a92ab

github.com/JFcamp